

Rapport de conception

Conception d'un Système de Détection d'Intrusion Réseau par Apprentissage Automatique appliqué au jeu de données CICIDS.

Réalisé par : Ait El Hadj Mohamed

Encadre par : M. Azizi Mohamed Saad

Année universitaire : 2026-2027

Table des matières

<i>Rapport de conception</i>	1
1. Introduction	4
2. Objectif du projet	4
3. Jeu de données choisi	5
4.1 Présentation du jeu de données	5
4.2 Justification du choix	5
4.3 Caractéristiques du jeu de données	6
4.4 Analyse préliminaire des données	6
4. Prétraitement des données (Data Preprocessing)	7
5.1 Fusion des fichiers du jeu de données	8
5.2 Analyse de la qualité des données	8
5.3 Suppression des doublons	8
5.4 Traitement des valeurs infinies et des valeurs manquantes	9
5.5 Encodage de la variable cible	9
5.6 Séparation des données	9
5.7 Résultat du prétraitement	10

1. Introduction

Après avoir étudié la problématique de la détection d'intrusions et analysé les solutions existantes, cette deuxième phase est consacrée à la conception de la solution proposée. Son objectif est de définir l'architecture générale du système, de sélectionner les technologies nécessaires à son développement et de préparer l'environnement de travail ainsi que les données qui seront utilisées tout au long du projet.

Dans le cadre de ce projet, le jeu de données public **CICIDS2017** a été retenu en raison de sa richesse, de la diversité des attaques qu'il contient et de son utilisation fréquente dans les travaux de recherche sur les systèmes de détection d'intrusions basés sur l'apprentissage automatique. Une analyse exploratoire des données a été réalisée afin de mieux comprendre leur structure, d'identifier les éventuelles anomalies (doublons, valeurs manquantes et valeurs infinies) et de définir les opérations de prétraitement nécessaires avant l'entraînement des modèles.

Cette phase présente également l'architecture fonctionnelle de la solution, l'organisation du projet, les outils de développement retenus ainsi que la méthodologie qui sera suivie pour la réalisation. Ces choix constituent une base solide pour la phase d'implémentation, au cours de laquelle les modèles d'apprentissage automatique seront développés, évalués et intégrés dans une application permettant de détecter les intrusions à partir de flux réseau.

2. Objectif du projet

L'objectif principal de ce projet est de concevoir et de développer un système de détection d'intrusions réseau basé sur l'apprentissage automatique à partir de jeux de données publics. La solution a pour but d'analyser les caractéristiques des flux réseau afin de distinguer automatiquement le trafic légitime des différents types d'attaques informatiques.

Pour atteindre cet objectif, le projet s'appuie sur le jeu de données **CICIDS2017**, qui sera prétraité afin de garantir la qualité des données avant l'entraînement de plusieurs modèles de classification. Les performances de ces modèles seront ensuite comparées à l'aide de différentes métriques d'évaluation, telles que l'accuracy, la précision, le rappel et le score F1, afin d'identifier le modèle le plus performant.

Enfin, le modèle retenu sera intégré dans une application développée avec **Streamlit**, permettant à l'utilisateur d'importer un fichier de flux réseau, de lancer la détection des intrusions et de visualiser les résultats de manière simple et interactive.

3. Jeu de données choisi

4.1 Présentation du jeu de données

Dans le cadre de ce projet, le jeu de données **CICIDS2017 (Canadian Institute for Cybersecurity Intrusion Detection System 2017)** a été retenu. Développé par le **Canadian Institute for Cybersecurity (CIC)** de l'Université du Nouveau-Brunswick, il constitue aujourd'hui l'un des jeux de données de référence pour l'évaluation des systèmes de détection d'intrusions basés sur l'apprentissage automatique.

Ce jeu de données a été conçu afin de reproduire un environnement réseau réaliste combinant un trafic légitime et plusieurs scénarios d'attaques représentatifs des menaces actuelles. Les données sont fournies sous forme de flux réseau (network flows) extraits à partir de captures de trafic et décrits par un ensemble de caractéristiques statistiques permettant de distinguer un comportement normal d'un comportement malveillant.

4.2 Justification du choix

Le choix de **CICIDS2017** repose sur plusieurs critères.

- Il est librement accessible et largement utilisé dans les travaux de recherche sur les systèmes de détection d'intrusions.
- Il contient un trafic réseau réaliste généré dans un environnement contrôlé.
- Il couvre plusieurs familles d'attaques modernes telles que **DDoS**, **DoS**, **PortScan**, **Bot**, **FTP-Patator**, **SSH-Patator**, **Heartbleed**, **Infiltration** et différentes attaques Web.
- Les données sont déjà transformées en caractéristiques numériques, ce qui facilite leur exploitation par les algorithmes d'apprentissage automatique.
- Son utilisation permet de comparer les résultats obtenus avec ceux de nombreuses publications scientifiques.

4.3 Caractéristiques du jeu de données

Le jeu de données est réparti sur **8 fichiers CSV**, représentant plusieurs journées de trafic réseau. Après regroupement, il contient **2 830 743 flux réseau**, chacun décrit par **79 colonnes**, dont **78 caractéristiques** et **une colonne d'étiquette (Label)** indiquant la classe du trafic.

Les principales caractéristiques décrivent notamment :

- La durée des connexions ;
- Le nombre de paquets échangés ;
- Le volume de données transférées ;
- Les délais entre les paquets (IAT) ;
- Les différents indicateurs liés aux protocoles TCP/IP.

Ces informations constituent les variables d'entrée utilisées par les modèles d'apprentissage automatique pour identifier les intrusions.

4.4 Analyse préliminaire des données

Une analyse exploratoire (EDA) a été réalisée afin d'évaluer la qualité du jeu de données avant son utilisation. Cette analyse a permis d'identifier la présence de doublons, de quelques valeurs manquantes ainsi que de valeurs infinies dans certaines variables. Ces anomalies seront corrigées durant la phase de prétraitement afin de garantir la qualité des données utilisées pour l'entraînement des modèles.

L'analyse de la distribution des classes montre également que le jeu de données est **déséquilibré**. En effet, le trafic légitime (**BENIGN**) représente environ **83 %** des observations, tandis que les différentes catégories d'attaques sont beaucoup moins représentées. Cette caractéristique reflète les conditions réelles des réseaux informatiques, où le trafic normal est largement majoritaire par rapport au trafic malveillant. Ce déséquilibre devra être pris en compte lors de l'évaluation des modèles afin d'éviter qu'une bonne précision globale masque de faibles performances sur les classes d'attaque. La répartition des observations est présentée dans le tableau ci-dessous.

<i>Classe</i>	<i>Pourcentage (%)</i>
<i>BENIGN</i>	83,11
<i>Ensemble des attaques</i>	16,89

Le jeu de données **CICIDS2017** couvre un large éventail de scénarios d'attaques représentatifs des principales menaces observées sur les réseaux informatiques modernes. Il regroupe à la fois du trafic légitime (**BENIGN**) et plusieurs catégories d'attaques ciblant différents services et protocoles, telles que les attaques par déni de service (DoS et DDoS), les scans de ports, les attaques par force brute, les attaques Web, les botnets ou encore les tentatives d'infiltration. Cette diversité permet d'évaluer les performances des modèles d'apprentissage automatique dans des contextes variés et de mesurer leur capacité à distinguer efficacement un trafic normal des différents comportements malveillants. Le tableau suivant présente les principales catégories d'attaques présentes dans le jeu de données.

Fichier	Lignes	Colonnes	Valeurs manquantes	Valeurs infinies	Doublons
Monday	529 918	79	64	810	26 935
Tuesday	445 909	79	201	327	24 065
Wednesday	692 703	79	1 008	1 586	81 909
Thursday Morning	170 366	79	20	250	6 066
Thursday Afternoon	288 602	79	18	396	35 630
Friday Morning	191 033	79	28	216	6 888
Friday Afternoon PortScan	286 467	79	15	727	72 353
Friday Afternoon DDoS	225 745	79	4	64	2 633
Total	2 830 743	79	1 358	4 376	256 479

4. Prétraitement des données (Data Preprocessing)

La qualité des données constitue un facteur déterminant dans les performances des modèles d'apprentissage automatique. En effet, un jeu de données contenant des doublons, des valeurs manquantes ou des valeurs aberrantes peut entraîner une baisse de précision des modèles et produire des résultats peu fiables. Afin de garantir la qualité des données utilisées dans ce projet, plusieurs opérations de prétraitement ont été réalisées avant la phase d'apprentissage.

5.1 Fusion des fichiers du jeu de données

Le jeu de données **CICIDS2017** est constitué de huit fichiers CSV correspondant à différentes journées de capture du trafic réseau. Chaque fichier contient des flux réseau associés à un ou plusieurs scénarios d'attaques.

Dans un premier temps, ces huit fichiers ont été fusionnés afin de constituer une base de données unique regroupant l'ensemble des observations. Cette fusion permet de disposer d'un jeu de données complet, couvrant l'ensemble des catégories d'attaques disponibles.

À l'issue de cette étape, le jeu de données comporte **2 830 743 flux réseau**, chacun décrit par **79 attributs**, dont **78 caractéristiques réseau** et **une variable cible (Label)** représentant la classe de chaque flux.

5.2 Analyse de la qualité des données

Une analyse exploratoire a ensuite été réalisée afin d'évaluer la qualité du jeu de données avant son exploitation. Cette étape a permis d'identifier plusieurs anomalies susceptibles d'affecter les performances des modèles d'apprentissage automatique.

Les principaux éléments observés sont :

- La présence de doublons ;
- Quelques valeurs manquantes réparties sur certaines variables ;
- Des valeurs infinies dans les variables **Flow Bytes/s** et **Flow Packets/s** ;
- Une forte prédominance de la classe **BENIGN**, traduisant un déséquilibre entre le trafic normal et les différentes catégories d'attaques.

Cette analyse a permis de définir les opérations de nettoyage nécessaires avant l'entraînement des modèles.

5.3 Suppression des doublons

Les doublons correspondent à des observations identiques présentes plusieurs fois dans le jeu de données. Leur présence peut introduire un biais lors de l'apprentissage en accordant une importance excessive à certaines observations.

Afin d'éviter ce phénomène, les lignes dupliquées ont été supprimées. Cette opération permet d'obtenir un jeu de données plus représentatif et d'améliorer la capacité de généralisation des modèles de classification.

5.4 Traitement des valeurs infinies et des valeurs manquantes

Certaines variables contenaient des valeurs infinies générées lors du calcul de caractéristiques statistiques telles que **Flow Bytes/s** et **Flow Packets/s**. Ces valeurs ne pouvant pas être traitées directement par les algorithmes de Machine Learning, elles ont été remplacées par des valeurs manquantes (*NaN*).

Par la suite, les lignes contenant des valeurs manquantes ont été supprimées. Cette approche a été retenue car le nombre de valeurs concernées reste très faible par rapport aux **plus de 2,8 millions d'observations**, ce qui limite fortement son impact sur la représentativité du jeu de données.

À l'issue de cette étape, le jeu de données ne contient plus de valeurs manquantes ni de valeurs infinies.

5.5 Encodage de la variable cible

La variable **Label** contient les différentes classes du jeu de données sous forme de chaînes de caractères (par exemple : *BENIGN*, *DDoS*, *PortScan* ou *Bot*).

Les algorithmes d'apprentissage automatique nécessitant une représentation numérique des variables cibles, les différentes classes ont été converties en valeurs entières grâce à la méthode **Label Encoding**. Cette transformation permet de conserver l'ensemble des catégories tout en les rendant compatibles avec les modèles de classification.

5.6 Séparation des données

Une fois le prétraitement terminé, le jeu de données est séparé en deux parties distinctes :

- Un **ensemble d'entraînement (Training Set)**, utilisé pour apprendre les caractéristiques des différentes classes ;
- Un **ensemble de test (Test Set)**, utilisé pour évaluer les performances des modèles sur des données jamais observées durant l'apprentissage.

Dans ce projet, une répartition de **80 %** des données pour l'entraînement et **20 %** pour les tests a été retenue. Cette méthode constitue une pratique couramment utilisée dans les projets d'apprentissage automatique et permet d'obtenir une évaluation fiable des modèles développés.

5.7 Résultat du prétraitement

À l'issue de cette phase, le jeu de données est entièrement préparé pour l'apprentissage automatique. Les différentes opérations de fusion, de nettoyage, de suppression des anomalies, d'encodage des classes et de séparation des données permettent d'obtenir un ensemble de données cohérent, fiable et directement exploitable par les algorithmes de classification.

Cette étape constitue une base essentielle pour la phase suivante du projet, consacrée à l'entraînement, à la comparaison et à l'évaluation des modèles de détection d'intrusions.